

# 文本分析 (三): 大语言模型及其应用

汪小圈

2025-05-26

# Word2Vec 的局限性

- 一词一向量问题：每个词只对应一个固定的向量，无法处理一词多义
- 上下文无关：词向量无法捕捉词语在特定上下文中的含义变化
- 长距离依赖问题：无法捕捉句子中相距较远的词之间的依赖关系
- 表达能力有限：固定维度的向量难以编码复杂的语言知识和语法结构

# 上下文感知的词表示

- **动态表示**: 同一个词在不同上下文中具有不同的向量表示
- **语义消歧**: 能够根据上下文区分多义词的不同含义
- **句法感知**: 能够捕捉词语在句子中的句法功能
- **长距离依赖**: 能够建模句子中远距离词语之间的关系

一个词的含义不仅取决于它自身，更取决于它的上下文环境

# 语言模型：理解上下文的基础

语言模型的基本任务：预测序列中的下一个词

$$P(w_t | w_1, w_2, \dots, w_{t-1})$$

不同类型的语言模型：

- 传统 **n-gram** 语言模型：  $P(w_t | w_{t-2}, w_{t-1})$
- 循环神经网络 (**RNN**) 语言模型：通过隐藏状态递归编码全部历史
- 双向语言模型：同时考虑左侧和右侧上下文
- **Transformer** 语言模型：通过注意力机制直接建模所有位置间的依赖关系

# 从 ELMo 到 BERT 的演进

**ELMo (2018)** - 双层双向 LSTM 结构 - 前向和后向语言模型结合 - 不同层表示加权组合 - 有效解决一词多义问题

**GPT (2018)** - 单向 Transformer 结构 - 仅使用前向语言模型 - 基于 Transformer 解码器 - 大规模预训练 + 微调范式

# BERT (2018)

- 使用双向 Transformer 编码器
- 采用掩码语言模型 (Masked LM) 预训练
- 同时使用下一句预测 (NSP) 任务
- 极大提升了 NLP 任务的性能上限

BERT 预训练目标：预测被掩码的词

$$L(\mathcal{D}) = \sum_{i \in \mathcal{M}} \log P(w_i | w_{\neg \mathcal{M}}; \Theta)$$

# Transformer 架构: BERT 的基础

自注意力机制是 Transformer 的核心组件:

- ① 将输入向量  $X$  转换为查询 (Q)、键 (K) 和值 (V):

$$Q = XW^Q, K = XW^K, V = XW^V$$

- ② 计算注意力得分并归一化:

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

优势: - 可以捕捉任意距离的依赖关系 - 计算复杂度低, 允许并行计算

# 多头注意力与位置编码

多头注意力:

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O$$

其中,  $head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$

位置编码:

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}})$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}})$$



# Transformer 编码器结构

一个完整的 Transformer 编码器层包含：

- ① 多头自注意力机制
- ② 层归一化 (Layer Normalization)
- ③ 前馈神经网络 (Feed-Forward Network)
- ④ 残差连接 (Residual Connection)

组合方式：

$$\hat{h} = \text{LayerNorm}(x + \text{MultiHeadAttention}(x))$$

$$h = \text{LayerNorm}(\hat{h} + \text{FFN}(\hat{h}))$$

# BERT 的输入表示

BERT 的输入由三种嵌入的总和组成：

- 词嵌入：WordPiece 词表中的词元对应的嵌入
- 段嵌入：区分句子对中的第一句和第二句
- 位置嵌入：表示词元在序列中的位置

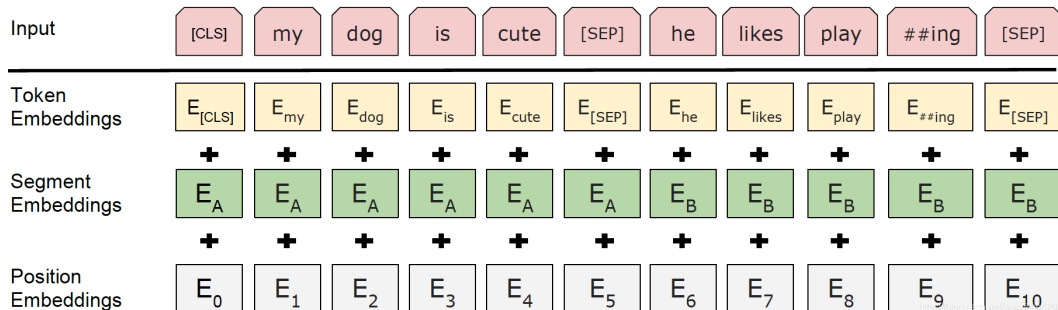


图 1: BERT 输入表示

# BERT 的预训练任务

## ❶ 掩码语言模型 (Masked LM):

- 随机掩盖输入中 15% 的词元
- 80% 用 [MASK] 替换, 10% 用随机词替换, 10% 保持不变
- 训练模型预测被掩盖的原始词元

## ❷ 下一句预测 (Next Sentence Prediction):

- 预测第二句是否是第一句的真实后续
- 训练数据中 50% 是真实连续句子, 50% 是随机句子对

# BERT 的模型变体

## BERT-Base:

- 12 层 Transformer 编码器
- 12 个注意力头
- 768 维隐藏层
- 1.1 亿参数

## BERT-Large:

- 24 层 Transformer 编码器
- 16 个注意力头
- 1024 维隐藏层
- 3.4 亿参数

# BERT 的微调方式

- **序列级任务**（如分类）：使用 **[CLS]** 标记的最终隐藏状态
- **词元级任务**（如 NER）：使用每个词元的最终隐藏状态
- **句子对任务**（如问答）：同时输入问题和段落，识别答案跨度

微调过程通常只需要少量标注数据和训练轮次

# BERT 的内部工作机制

## 层次化语言知识:

- 底层 (1-4 层): 表面语法特征、词性、局部依赖
- 中层 (5-8 层): 短语级语义和共指关系
- 高层 (9-12 层): 长距离依赖和抽象语义关系

## 注意力头的专业化:

- 语法头: 关注句法依赖关系
- 语义头: 关注语义相关的词
- 共指头: 关注指代同一实体的表达

# BERT 的后续演进

## 预训练任务优化:

- **RoBERTa**: 移除 NSP 任务, 更大批量和更多数据
- **ALBERT**: 参数共享和分解嵌入
- **ELECTRA**: 判别式替换检测训练

## 知识增强:

- **KnowBERT**: 集成知识库信息
- **ERNIE**: 加入实体和短语级掩码
- **FinBERT**: 针对金融领域的专业知识

## 模型架构改进:

- **SpanBERT**: 掩盖连续文本片段
- **XLNet**: 排列语言模型
- **DeBERTa**: 解耦注意力机制

# Transformer 架构的扩展

## 编码器-解码器结构:

- 编码器: 处理输入序列, 生成上下文表示
- 解码器: 基于编码器输出生成目标序列
- 交叉注意力: 解码器通过注意力机制访问编码器输出
- 代表模型: T5, BART

## 仅解码器架构:

- 单向自注意力: 每个位置只能看到其前面的位置
- 自回归生成: 逐词生成输出序列
- 代表模型: GPT 系列, LLaMA



# 大型语言模型的关键创新

## 规模扩展:

- 从亿级参数到千亿参数
- 训练数据从 GB 级到 TB 级
- 计算资源大幅增长

## 涌现能力 (Emergent Abilities):

- 指令跟随: 理解并执行自然语言指令
- 思维链推理: 通过分步骤推理解决复杂问题
- 上下文学习: 从少量示例中学习新任务

# 提示工程与思维链推理

## 提示工程 (Prompt Engineering):

- 通过精心设计的提示引导模型行为
- 不同于传统的微调范式
- 灵活调整模型输出

## 思维链推理 (Chain-of-Thought):

- 让模型先生成推理过程，再给出结论
- 显著提高解决复杂问题的能力
- Prompt + 思考过程 → 更准确的结果

## 上下文学习 (In-context Learning):

- 在提示中包含示例，引导模型学习模式
- 无需参数更新，即可适应新任务

# 代表性大型语言模型

## GPT 系列:

- **GPT-1** (2018): 1.17 亿参数
- **GPT-2** (2019): 15 亿参数
- **GPT-3** (2020): 1750 亿参数
- **GPT-4** (2023): >1 万亿参数 (估计)

## 开源大模型:

- **LLaMA** 系列: 7B-65B 参数
- **ChatGLM**: 双语模型
- **DeepSeek**: 专注长序列处理
- **Qwen**: 阿里云开发

## 信息提取与分析：

- 报告解析（财报关键指标提取、研报摘要）
- 市场情感分析（新闻情绪、投资者情绪）
- 事件提取（财经新闻事件识别、因果关系分析）

## 金融文本生成：

- 研究报告生成（财务分析、行业趋势报告）
- 监管合规（合规声明、文档检查）
- 客户交互（智能金融顾问、投资建议）

# 大语言模型在金融分析中的最佳实践

## 提示设计技巧：

- 明确任务界定（指定分析目标和输出格式）
- 思维链设计（引导模型分步思考）
- 角色设定（指定专业角色，如” 金融分析师”）

## 金融特定优化：

- 上下文补充（提供行业背景信息）
- 多模型比较（通用模型与金融专业模型对比）
- 人机协作（模型输出作为专业分析起点）

## 局限性与注意事项：

- 事实准确性（需要人工验证）
- 偏见风险（保持客观中立）
- 时效性限制（及时更新分析）

# 从静态向量到大语言模型的演进

- **表示方法演进**：从静态词向量到上下文感知的动态表示
- **架构演进**：从浅层神经网络到深层 Transformer 架构
- **规模演进**：从百万参数到千亿参数
- **应用演进**：从特征提取到端到端文本理解与生成

# 无监督学习的新范式

- 零样本学习：无需额外标注数据，直接分类新数据
- 上下文学习：通过提示中的示例引导模型学习模式
- 涌现能力：模型规模增长带来质的飞跃
- 提示工程：通过设计提示引导模型行为